

TP3 ANAC++

VUACHET Luigi

Décembre 2023

1 Discrétisation par différences finies

(1.1)

$\rho(x_1, x_2) = 1 \quad \forall (x_1, x_2) \in \Omega$

$T \in C^4(\Omega)$ vérifie :

$$\begin{cases} -\text{div}(\rho \Delta T) = 0 \text{ dans } \Omega \\ T = T_D \text{ sur } \partial\Omega_D \\ \Delta T * n = 0 \text{ sur } \partial\Omega_N \end{cases}$$

On a :

$$\Delta T(x_1, x_2) = \left(\frac{\partial T}{\partial x_1}, \frac{\partial T}{\partial x_2} \right)$$

$$-\text{div}(\rho \Delta T) = -\text{div}(\Delta T) = -\frac{\partial \Delta T_1}{\partial x_1} - \frac{\partial \Delta T_2}{\partial x_2} = -\frac{\partial^2 T}{\partial x_1^2} - \frac{\partial^2 T}{\partial x_2^2}$$

Pour h suffisamment petit :

$$T(x+h, y) = T(x, y) + h \frac{\partial T(x, y)}{\partial x_1} + \frac{h^2}{2} \frac{\partial^2 T(x, y)}{\partial x_1^2} + \frac{h^3}{6} \frac{\partial^3 T(x, y)}{\partial x_1^3} + o(h^4)$$

$$T(x, y+h) = T(x, y) + h \frac{\partial T(x, y)}{\partial x_2} + \frac{h^2}{2} \frac{\partial^2 T(x, y)}{\partial x_2^2} + \frac{h^3}{6} \frac{\partial^3 T(x, y)}{\partial x_2^3} + o(h^4)$$

Par conséquent, $\frac{4T(x, y) - T(x-h, y) - T(x+h, y) - T(x, y-h) - T(x, y+h)}{h^2}$ est une approximation de $-\text{div}(\Delta T)$.

De plus, $\frac{T(x+h, y) - T(x-h, y)}{2h}$ est une approximation d'ordre 2 de $\frac{\partial T}{\partial x_1}$.

Sur $\partial\Omega_D$, $T(x, 0) = 50$ et $T(x, 1) = 100$

On en déduit la discrétisation du système d'équations linéaires suivant :

$$\begin{cases} \frac{4T_{i,j} - T_{i-1,j} - T_{i+1,j} - T_{i,j-1} - T_{i,j+1}}{h^2} = 0, \quad \forall 1 \leq i, j \leq N \\ T_{i,0} = 100, \quad T_{i,N+1} = 50 \quad \forall i = 0, \dots, N+1 \\ T_{-1,j} = T_{1,j}, \quad T_{N+2,j} = T_{N,j} \quad \forall j = 1, \dots, N \end{cases}$$

(1.2) Pour, $\rho \in C^2(\Omega)$ et h petit :

$$\frac{[\rho(x_1 + \frac{h}{2}, x_2) + \rho(x_1 - \frac{h}{2}, x_2)]T(x_1, x_2) - \rho(x_1 + \frac{h}{2}, x_2)T(x_1 + h, x_2) - \rho(x_1 - \frac{h}{2}, x_2)T(x_1 - h, x_2)}{h^2} = -\frac{\partial}{\partial x_1} \left(\rho \frac{\partial T}{\partial x_1} \right) (x_1, x_2) + O(h^2)$$

$$\frac{[\rho(x_1, x_2 + \frac{h}{2}) + \rho(x_1, x_2 - \frac{h}{2})]T(x_1, x_2) - \rho(x_1, x_2 + \frac{h}{2})T(x_1, x_2 + h) - \rho(x_1, x_2 - \frac{h}{2})T(x_1, x_2 - h)}{h^2} = -\frac{\partial}{\partial x_2} \left(\rho \frac{\partial T}{\partial x_2} \right) (x_1, x_2) + O(h^2)$$

La somme de ces deux égalités est une approximation de $div(\Delta T)(x_1, x_2)$.

On en déduit la discrétisation du système linéaire suivante :

$$\begin{cases} \frac{[\rho_{i+\frac{1}{2},j} + \rho_{i-\frac{1}{2},j} + \rho_{i,j+\frac{1}{2}} + \rho_{i,j-\frac{1}{2}}]T_{i,j} - \rho_{i-\frac{1}{2},j}T_{i-1,j} - \rho_{i+\frac{1}{2},j}T_{i+1,j} - \rho_{i,j-\frac{1}{2}}T_{i,j-1} - \rho_{i,j+\frac{1}{2}}T_{i,j+1}}{h^2} = 0, & \forall 1 \leq i, j \leq N \\ T_{i,0} = 100, & T_{i,N+1} = 50 \quad \forall i = 0, \dots, N+1 \\ T_{-1,j} = T_{1,j}, & T_{N+2,j} = T_{N,j} \quad \forall j = 1, \dots, N \end{cases}$$

(1.3)

Numérotons les inconnues suivant l'ordre lexicographique

$$T_{0,0}, T_{1,0}, \dots, T_{N+1,0}, T_{0,1}, T_{1,1}, \dots, T_{N+1,1}, \dots$$

Pour $N=3$, $h = \frac{1}{N+1}$, on a :

$$\underbrace{\frac{1}{h^2} \begin{pmatrix} B & -\text{Id}_5 & 0 \\ -\text{Id}_5 & B & -\text{Id}_5 \\ 0 & -\text{Id}_5 & B \end{pmatrix}}_A \times \begin{pmatrix} T_{0,1} \\ T_{1,1} \\ T_{2,1} \\ T_{3,1} \\ T_{4,1} \\ T_{0,2} \\ T_{1,2} \\ T_{2,2} \\ T_{3,2} \\ T_{4,2} \\ T_{0,3} \\ T_{1,3} \\ T_{2,3} \\ T_{3,3} \\ T_{4,3} \end{pmatrix} = \begin{pmatrix} \frac{1}{h^2} T_{0,0} \\ \frac{1}{h^2} T_{1,0} \\ \frac{1}{h^2} T_{2,0} \\ \frac{1}{h^2} T_{3,0} \\ \frac{1}{h^2} T_{4,0} \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ \frac{1}{h^2} T_{0,4} \\ \frac{1}{h^2} T_{1,4} \\ \frac{1}{h^2} T_{2,4} \\ \frac{1}{h^2} T_{3,4} \\ \frac{1}{h^2} T_{4,4} \end{pmatrix} = \underbrace{\begin{pmatrix} \frac{1}{h^2} T_{0,0} \\ \frac{1}{h^2} T_{1,0} \\ \frac{1}{h^2} T_{2,0} \\ \frac{1}{h^2} T_{3,0} \\ \frac{1}{h^2} T_{4,0} \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ \frac{1}{h^2} T_{0,4} \\ \frac{1}{h^2} T_{1,4} \\ \frac{1}{h^2} T_{2,4} \\ \frac{1}{h^2} T_{3,4} \\ \frac{1}{h^2} T_{4,4} \end{pmatrix}}_b$$

$$\text{avec } B = \begin{pmatrix} 4 & -2 & 0 & 0 & 0 \\ -1 & 4 & -1 & 0 & 0 \\ 0 & -1 & 4 & -1 & 0 \\ 0 & 0 & -1 & 4 & -1 \\ 0 & 0 & 0 & -2 & 4 \end{pmatrix}$$

$$\begin{pmatrix} 10 \\ 10 \\ 10 \\ 10 \\ 10 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 5 \\ 5 \\ 5 \\ 5 \\ 5 \end{pmatrix}$$

Les conditions aux limites donne que $b = 160$

Comme B n'est pas symétrique, A n'est pas symétrique.

On remarque que l'on peut diviser les étapes du système linéaire sans que cela change la solution. Ce qui revient à diviser une ligne de A et la ligne de b correspondante par le même nombre. On effectue la symétrisation de A en divisant par 2 la première et la dernière ligne de B à chaque fois que B apparaît dans A. Ainsi, on obtient :

$$\underbrace{\frac{1}{h^2} \begin{pmatrix} \tilde{B} & -\tilde{I} & 0 \\ -\tilde{I} & \tilde{B} & -\tilde{I} \\ 0 & -\tilde{I} & \tilde{B} \end{pmatrix}}_{\tilde{A}} \times \begin{pmatrix} T_{0,1} \\ T_{1,1} \\ T_{2,1} \\ T_{3,1} \\ T_{4,1} \\ T_{0,2} \\ T_{1,2} \\ T_{2,2} \\ T_{3,2} \\ T_{4,2} \\ T_{0,3} \\ T_{1,3} \\ T_{2,3} \\ T_{3,3} \\ T_{4,3} \end{pmatrix} = \begin{pmatrix} \frac{1}{2h^2} T_{0,0} \\ \frac{1}{h^2} T_{1,0} \\ \frac{1}{h^2} T_{2,0} \\ \frac{1}{h^2} T_{3,0} \\ \frac{1}{2h^2} T_{4,0} \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ \frac{1}{2h^2} T_{0,4} \\ \frac{1}{h^2} T_{1,4} \\ \frac{1}{h^2} T_{2,4} \\ \frac{1}{h^2} T_{3,4} \\ \frac{1}{2h^2} T_{4,4} \end{pmatrix}$$

$$\text{avec } \tilde{B} = \begin{pmatrix} 2 & -1 & 0 & 0 & 0 \\ -1 & 4 & -1 & 0 & 0 \\ 0 & -1 & 4 & -1 & 0 \\ 0 & 0 & -1 & 4 & -1 \\ 0 & 0 & 0 & -1 & 2 \end{pmatrix} \text{ et } \tilde{I} = \begin{pmatrix} \frac{1}{2} & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{2} \end{pmatrix}$$

$\tilde{A}$ est à diagonale dominante et est hermitienne. De plus les coefficients de la diagonale sont des réels positifs donc $\tilde{A}$ est positive (corollaire du théorème de Gerschgorin). De plus $\tilde{A}$ est inversible, donc définie positive.

- On constitue la classe **matricebande** qui hérite des champs et méthodes de la classe **matrice** et qui met en place le stockage bande de $\tilde{A}$. A est symétrique et ne contient que trois diagonales non nulles. Il suffit de stocker les diagonales dans *ATAB* et les positions de diagonales dans un vecteurs d'entier *indice*.
- La fonction *laplacien* prend en entrée un entier $N > 1$. Elle renvoie la matrice de coefficients associée au systèmes d'équations (1.1) qui a été rendu symétrique. Cette fonction remplit les tableaux *ATAB* et *indice* de la partie inférieure.
- La fonction *laplacien* prend en entrée un entier $N > 1$. Elle utilise la fonction *rho* de la classe **matricebande** qui prend en entrée l'indice i, j correspondant au point $x_{i,j}$ du maillage et l'entier N du laplacien. En particulier pour $h_N = \frac{1}{N+1}$:

$$\rho(i, j, N) = \begin{cases} 10 & \text{si } 0.25 \leq ih_N \leq 0.75 \text{ , } 0.4 \leq jh_N \leq 0.6 \\ 1 & \text{sinon} \end{cases}$$

$\rho(\frac{1}{2}, j, N) = \rho(-\frac{1}{2}, j, N)$ et $\rho(N + \frac{3}{2}, j, N) = \rho(N + \frac{1}{2}, j, N)$

La fonction laplacien renvoie la matrice de coefficients associée au système d'équations (1.2) qui a été rendu symétrique. Cette fonction remplit les tableaux *ATAB* et *indice* de la partie inférieure.

- L'opérateur * est surchargé dans la classe **matricebande** et prend en entrée un vecteur x et renvoie le vecteur $y = \tilde{A}x$ avec $\tilde{A}$ symétrique en stockage bande.
- La fonction amie smbr et smbr_rho prend en entrée la matrice $\tilde{A}$ et $N > 1$. Elles remplissent le vecteur b de la classe **matricebande** avec le vecteur correspondant au second membre du système respectivement (1.1) et (1.2) "symétrisé".

Par exemple, pour $N=3$ le second membre c du système "symétrisé" (1.2) s'écrit :

$$c = \begin{pmatrix} \frac{1}{2h^2}\rho_{0,\frac{1}{2}}T_{0,0} \\ \frac{1}{h^2}\rho_{1,\frac{1}{2}}T_{1,0} \\ \frac{1}{h^2}\rho_{2,\frac{1}{2}}T_{2,0} \\ \frac{1}{h^2}\rho_{3,\frac{1}{2}}T_{3,0} \\ \frac{1}{2h^2}\rho_{4,\frac{1}{2}}T_{4,0} \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ \frac{1}{2h^2}\rho_{0,3+\frac{1}{2}}T_{0,4} \\ \frac{1}{h^2}\rho_{1,3+\frac{1}{2}}T_{1,4} \\ \frac{1}{h^2}\rho_{2,3+\frac{1}{2}}T_{2,4} \\ \frac{1}{h^2}\rho_{3,3+\frac{1}{2}}T_{3,4} \\ \frac{1}{2h^2}\rho_{4,3+\frac{1}{2}}T_{4,4} \end{pmatrix} \quad \text{avec} \quad h = \frac{1}{N+1}$$

2 Méthode du gradient à pas optimal et à pas fixe

Pour tout les calculs qui nécessitent une norme sur $\mathbb{R}^p$, la norme utilisé est la norme infinie.

- La fonction steepest_descent de la classe **matricebande** est la méthode de gradient à pas optimale. Elle prend en entrée le vecteur b, un vecteur de vecteur x contenant x_0 et le paramètre tol. En sortie elle envoie la structure mgrad composé du vecteur x, du nombre d'itérations k et du vecteur nrb des $\frac{\|r_k\|}{\|b\|}$.
- La fonction steepest_descent de la classe **matricebande** est la méthode de gradient à pas constant. Elle prend en entrée le vecteur b, un vecteur de vecteur x contenant x_0 , le paramètre tol et le pas α . De même, elle envoie la structure mgrad.

Dans le cas du système linéaire donnée dans le cas (1.1), $\frac{1}{\alpha_{opt}}$ est ap-


proximativement donnée par la plus grande valeur diagonale de $\tilde{A}$ soit $\alpha_{opt} = \frac{1}{64}$.


On applique les méthodes de gradient pour le système linéaire donné dans le cas (1.1).

Pour la méthode de gradient à pas fixe de paramètre $\alpha = \frac{j\alpha_{opt}}{5}$ pour $j = 1, \dots, 6$ et la méthode du gradient à pas optimal :

méthode à pas ...	nombre d'itérations avant la conditions d'arrêt
optimale	68
constant j=1	150
constant j=2	150
constant j=3	120
constant j=4	89
constant j=5	70
constant j=6	143 (erreur OVERFLOW)

On remarque que la méthode du gradient à pas optimale converge plus rapidement que pour la méthode à pas fixe. De plus, cette dernière peut diverger lorsque α est trop grand (comme pour j=6).





On voit que le reste de la méthode de descente à pas constant pour $j=5$ converge presque de la même façon que pour la méthode à pas optimale. On remarque que plus les pas sont petit, moins le reste diminue rapidement. En revanche, pour des pas trop grand la méthode diverge ($j=6$).


3 Méthode PCG de gradient conjugué avec pré-conditionnement


- La fonction `assemblageT` de **matricebande** prend en entrée un *choix* $\in \{1, 2, 3\}$ et le paramètre ω . Elle remplit les tableaux `ttab` et `tind` présent dans la classe pour le choix du préconditionneur.
- La fonction `preconditionne` de **matricebande** prend en entrée un vecteur r . Elle remplit le vecteur z tel que $TT^T z = r$ en effectuant une descente puis une remontée. T est sous format bande et stocké dans `ttab` et `tind`. Il faut faire appel à `assemblage T` avant.
- La fonction `PCG` de **matricebande** prend en entrée le paramètre `tol`, en entrée le vecteur x contenant x_0 . A et T sont stocké dans la classe. La

fonction renvoie la structure mgrad.

On applique la fonction PCG au systèmes linéaires (1.1) et (1.2) pour $N=20$. Pour différents choix de préconditionneur appliqués aux systèmes linéaires, on obtient le nombre d'itérations avant la condition d'arrêt :

choix \ système	(1.1)	(1.2)
1	49	87
2	21	51
3 pour $\omega = 0$	15	19
3 pour $\omega = \frac{1}{20}$	16	21
3 pour $\omega = \frac{1}{\sqrt{20}}$	17	25





On remarque que pour la troisième choix d'assemblage, la méthode du gradient converge significativement plus rapidement vers la solution pour un bon choix de ω . En particulier, plus ω est proche de 0, plus la méthode converge rapidement. Aussi le reste fluctue moins pour que pour les autres choix d'assemblage. Le deuxième choix est un meilleur choix que le premier.